


Чекпоинты:

- 1. Организационный
- 2. Сбор данных
- 3. EDA
- 4. Базовые модельки

Организационный

- Собрались, сделали репозиторий
- Выбрали тему музыкальные рекомендации
- Датасет Плейлисты юзеров из спотифая и описания музыки, заскрапленные со спотифая
- Конечный формат веб приложение




https://github.com/orson88/hse_mlds_recsys_project


Сбор данных

- Нашли данные, заскрапили прочие фичи со Спотифая
- Набрали статей по акустическим фичам данных не нашлось
- Датасет Плейлисты юзеров из спотифая и описания музыки, заскрапленные со спотифая
- Конечный формат веб приложение

https://www.kaggle.com/datasets/andrewmvd/spotify-playlists

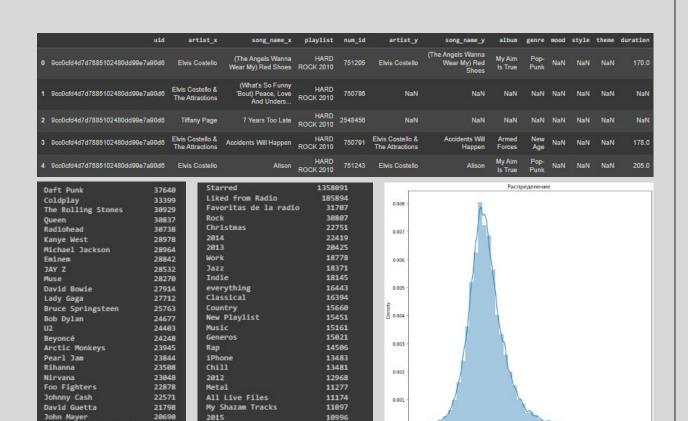
https://rapidapi.com/theaudiodb/api/theaudiodb/





EDA

- Принято решение выбирать топ 10000 песен (артист+песня). Получили общее представление о структуре данных.
- ∘ 16 т. юзеров
- ∘ 2.8 млн. песен



10876

Name: playlist, dtype: int64

300

https://colab.research.google.com/drive/1PTA-3IWY0VAryFYCLk2HJx86NWc5ofu1?usp=sharing

Red Hot Chili Peppers


Name: artist_x, dtype: int64

20527

Модели

- Практиковались в LightFM и Inmplicit, библиотеках для recsys моделей и нужных матричных преобразований.
- Разбили трейн и тест рандомно, проверив наличие всех тест-юзеров в трейне
- Выбрали Precision@K

Precision@K = 0.55



https://colab.research.google.com/drive/1PTA-3IWY0VAryFYCLk2HJx86NWc5ofu1?usp=sharing

Планы

- Сервис на FastAPI
- Использовать доп. Фичи

docker

• Другие модели

